


É possível identificar clientes com maior risco de **inadimplência**?

Classificação de risco de crédito a partir
do histórico de pagamentos e das
características dos clientes.



O risco está concentrado em uma **minoria dos clientes**

Distribuição dos clientes na base



88,23%

Bons pagadores

32.166 clientes

11,77%

Maus pagadores

4.291 clientes



Como definimos um mau pagador?

Cliente que apresentou pelo menos uma ocorrência de atraso igual ou superior a 30 dias no histórico disponível.

TARGET = 1

Ocorrência de STATUS entre 1 e 5

TARGET = 0

Nenhuma ocorrência de atraso ≥ 30 dias



O desafio não é apenas prever corretamente — é identificar uma **classe minoritária** sem confundir bons clientes com clientes de maior risco.

Do histórico de pagamentos a um **modelo de classificação**

Transformamos os dados brutos em uma base preparada para identificar clientes com maior risco de inadimplência.

1 Duas bases de dados

 **application_record.csv**
Características dos clientes



 **credit_record.csv**
Histórico mensal de pagamentos

2 Construção do TARGET



Cliente com pelo menos uma ocorrência de atraso ≥ 30 dias no histórico.

TARGET = 1
Atraso ≥ 30 dias

TARGET = 0
Nenhuma ocorrência de atraso ≥ 30 dias

3 Preparação dos dados



- ✓ Tratamento de ausências
- ✓ Codificação das variáveis categóricas
- ✓ Padronização das variáveis numéricas
- ✓ Criação de variáveis a partir do histórico de pagamentos

4 Separação da base



80%
Treino
~ 29.166 clientes

20%
Teste
~ 7.291 clientes

Divisão estratificada
Mantém a mesma proporção de bons e maus pagadores nas duas bases.

5 Modelagem



Treinamento e comparação de diferentes algoritmos de classificação.



O conjunto de teste permaneceu isolado durante a seleção dos modelos.

Total de 36.457 clientes com histórico e cadastro disponíveis.

Entre os modelos avaliados, o **Random Forest** apresentou o melhor desempenho

Comparação dos modelos na validação cruzada (5 folds)

Modelo	PR-AUC Quanto maior, melhor	ROC-AUC Quanto maior, melhor
Regressão Logística	0,148	0,543
HistGradient Boosting	0,279	0,682
Random Forest	0,397	0,778



Como comparamos?

Validação cruzada estratificada com 5 folds.

Todos os modelos são avaliados repetidamente sobre os dados de treinamento, preservando a proporção entre bons e maus pagadores.

1

2

3

4

5

PR-AUC

Avalia a capacidade de identificar a classe minoritária (maus pagadores).

ROC-AUC

Avalia o desempenho geral do modelo em diferentes limiares.



Random Forest selecionado para a avaliação final no conjunto de teste.

O conjunto de teste ainda não participou dessa escolha.

No teste final, o modelo alcançou ROC-AUC de 0,805

Principais métricas no conjunto de teste



ROC-AUC

0,805

Avalia a capacidade de separação entre bons e maus pagadores em diferentes limiares.



PR-AUC

0,424

Avalia a capacidade de identificar a classe minoritária (maus pagadores).



7.292 clientes

Desempenho medido em clientes que não participaram da seleção do modelo.

Matriz de confusão

		Previsto	
		Bom pagador	Mau pagador
Real	Bom pagador	6.198 Verdadeiros negativos (TN)	236 Falsos positivos (FP)
	Mau pagador	582 Falsos negativos (FN)	276 Verdadeiros positivos (TP)



582

maus pagadores não foram identificados pelo limiar padrão.



276

maus pagadores identificados corretamente.

Identificação dos maus pagadores



Precisão

54%

Dos clientes classificados como maus pagadores, 54% realmente pertenciam a essa classe.



Recall

32%

O modelo identificou 32% dos maus pagadores existentes.



F1-score

0,40

Média harmônica entre precisão e recall.



Acurácia geral

89%

Percentual total de classificações corretas (majoritariamente bons pagadores).



O modelo consegue ordenar o risco, mas ainda deixa escapar uma parcela relevante dos maus pagadores.

Idade e tempo de emprego foram as **variáveis de maior importância preditiva**

Importância das variáveis no modelo (Permutation Importance)

Variável	Importância
Idade	0,105
Tempo de emprego	0,104
Tipo de renda	0,100
Posse de imóvel	0,068
Ocupação	0,065
Renda total	0,058
Escolaridade	0,054



Permutation Importance

Mede quanto o desempenho do modelo piora quando a informação de uma variável é embaralhada.

Quanto maior a queda no desempenho, **maior a dependência do modelo** daquela informação.

Principais insights

- ✓ Idade, tempo de emprego e tipo de renda foram as variáveis mais relevantes.
- ✓ O risco é influenciado por múltiplas características do perfil do cliente.
- ✓ A combinação das informações aumenta a capacidade preditiva do modelo.



O risco não é explicado por uma única característica.

O modelo ganha capacidade preditiva ao combinar diferentes informações do perfil do cliente.



Importância preditiva ≠ causalidade

Uma variável relevante para o modelo não necessariamente causa inadimplência.

É possível identificar risco — mas ainda há espaço para melhorar a decisão

O modelo apresenta capacidade preditiva relevante, mas ainda possui limitações, especialmente na identificação dos maus pagadores.



O modelo discrimina risco

O Random Forest demonstrou capacidade de diferenciar e ordenar clientes de diferentes níveis de risco.

ROC-AUC

no conjunto de teste

0,805



A classe de maior risco ainda é o desafio

Com o limiar padrão, uma parcela relevante dos maus pagadores ainda não é identificada.

Recall

(mau pagador)

32%



O risco resulta da combinação de informações

Idade, tempo de emprego e tipo de renda foram as características de maior importância preditiva, mas o desempenho surge da combinação de múltiplas variáveis.



Idade



Tempo
de emprego



Tipo de renda



Próximos passos

Evolução para uma aplicação em um contexto real de crédito.

1

Ajustar limiar de decisão

Equilibrar recall, precisão e custos do negócio.

2

Validação temporal

Testar o modelo em períodos mais recentes.

3

Incorporar critérios de negócio

Considerar políticas, custos e regras de crédito.

4

Monitoramento contínuo

Acompanhar desempenho e recalibrar o modelo.



Machine Learning não substitui a decisão de crédito: transforma dados históricos em informação adicional para apoiar essa decisão.